

Big Data & Data Analytics

Universidad Iberoamericana

Dr. Lázaro Bustio Martínez

lazaro.bustio@ibero.mx

Otoño de 2026

Actividad Práctica – Sesión 5

Detección de malware en APKs mediante Aprendizaje Automatizado

Esta sesión cierra el diplomado con un problema integral que aplica todo lo visto en las sesiones anteriores —manejo de datos con pandas, análisis exploratorio de datos y visualización—, sumando una introducción a Machine Learning (agrupamiento y clasificación) como cierre natural del curso.

Objetivo

Aplicar técnicas y algoritmos de Aprendizaje Automatizado y clasificación de datos para la detección de APKs (aplicaciones de Android) maliciosas, a partir del patrón de permisos que cada aplicación solicita.

Descripción de la actividad

Esta es una actividad guiada: el profesor desarrollará y explicará en vivo, durante la sesión, el notebook “Actividad Práctica - Sesión 5.ipynb”, que ya incluye todo el desarrollo, los resultados y las conclusiones del ejercicio. No es necesario entregar nada para esta sesión —no tiene una calificación asociada—; el objetivo es que el estudiante siga el razonamiento completo de un proyecto de análisis de datos, desde la pregunta de investigación hasta las conclusiones, integrando las herramientas vistas en el resto del diplomado.

El notebook está organizado siguiendo la metodología de un proyecto de Ciencia de Datos (vista en la Sesión 1): comprensión del problema, preguntas de investigación e hipótesis, preparación y análisis exploratorio de los datos, modelado (agrupamiento no supervisado y clasificación supervisada), y conclusiones que retoman y responden cada pregunta planteada al inicio.

Conjunto de datos

Se utiliza el archivo “apk_train.csv” (incluido en la carpeta de la sesión), compuesto por 398 muestras de aplicaciones de Android —199 maliciosas y 199 benignas—, donde cada muestra se representa mediante los permisos de Android que solicita (1 si lo solicita, 0 en caso contrario).

Bibliografía a revisar

Antes o durante la sesión, se recomienda revisar los siguientes documentos (incluidos en la carpeta “Bibliografía” de esta sesión) para entender el sistema de permisos de Android:

- “Android manifest file permissions” – permisos que Android pone a disposición de los desarrolladores.
- “A Comprehensive Analysis of the Android Permissions System” – arquitectura de permisos del sistema Android.

Contenido del notebook

Durante la sesión se recorrerán, entre otros, los siguientes puntos:

- Preguntas de investigación e hipótesis de partida.
- Análisis exploratorio de datos: balance de clases, distribución del total de permisos por APK, detección de valores atípicos.
- Identificación de los permisos más asociados a malware (uso de sort_values, filter y query sobre los datos de permisos).
- Visualización de los hallazgos con histogramas, boxplots, mapas de calor y un diagrama de radar.
- Agrupamiento no supervisado (KMeans) para comprobar si benignas y malignas son separables únicamente a partir del patrón de permisos.
- Clasificación supervisada (SVM, Random Forest y KNN), comparación de modelos con validación cruzada, y evaluación final sobre un conjunto de prueba nunca antes visto por el modelo.
- Conclusiones que retoman cada pregunta de investigación e hipótesis con la evidencia obtenida.

Materiales de la sesión

- Actividad Práctica - Sesión 5.ipynb (notebook principal, ya resuelto)
- apk_train.csv (conjunto de datos)
- Bibliografía/ (los dos documentos sobre permisos de Android)

Complementarios

Para quien desee profundizar por su cuenta después de la sesión:
<https://www.geeksforgeeks.org/top-data-science-projects/>